

Estudio sobre las fuentes de información desde la perspectiva de la informática

Documento técnico — actualización documental con referencias publicadas o vigentes en los últimos cinco años (2021–2026)

Resumen ejecutivo

Las fuentes de información son el origen de los datos que un sistema puede capturar, almacenar, procesar, intercambiar y convertir en conocimiento útil. Desde la informática, comprenden bases de datos, sistemas transaccionales, sensores, interfaces de programación (API), archivos, registros de eventos, repositorios documentales, servicios en la nube, portales de datos abiertos y contenidos web.

Su gestión determina la calidad de la analítica, la confiabilidad de los modelos de inteligencia artificial, la interoperabilidad, la seguridad de la información y la capacidad de auditar decisiones. El principio central es que un dato no debe evaluarse únicamente por estar disponible: debe demostrar origen, significado, calidad, vigencia, restricciones de uso y transformaciones aplicadas.

1. Concepto y alcance

Una fuente de información informática es cualquier recurso, sistema, dispositivo, persona o proceso capaz de originar, registrar, transmitir o disponibilizar datos susceptibles de tratamiento digital. En un ciclo típico, el flujo es: fuente → captura → almacenamiento → procesamiento → análisis → decisión o acción.

La procedencia de datos —también denominada data provenance— describe la cronología del origen, desarrollo, propiedad, ubicación y cambios que ha experimentado un dato o un componente de sistema. Esta evidencia permite reconstruir quién generó el dato, cuándo, con qué método, bajo qué controles y qué transformaciones recibió.

Preguntas de control

- ¿De dónde procede el dato y qué entidad, sistema o persona lo produjo?
- ¿Cómo fue recolectado, con qué frecuencia se actualiza y qué cobertura tiene?
- ¿Cuál es su estructura, formato, semántica y conjunto de metadatos?
- ¿Es exacto, completo, consistente, oportuno y pertinente para el propósito analítico?
- ¿Qué restricciones de seguridad, privacidad, licencia, propiedad intelectual y reutilización aplican?

2. Clasificación de las fuentes

2.1 Según el origen de los datos

Tipo	Definición	Ejemplos	Fortalezas y límites
Primarias	Generan el dato original por observación, medición, transacción o interacción directa.	Sensores IoT, encuestas digitales, formularios, GPS, POS, logs.	Alta cercanía al hecho observado; pueden existir fallas de medición, sesgos o vacíos.
Secundarias	Reutilizan, organizan, analizan o publican datos originados por terceros.	Informes, repositorios, dashboards, bases consolidadas.	Acceso ágil y menor costo; pueden perder detalle o estar desactualizadas.

Tipo	Definición	Ejemplos	Fortalezas y límites
Terciarias	Facilitan localizar y navegar hacia fuentes primarias o secundarias.	Catálogos, índices, buscadores, directorios y bibliografías.	Mejoran el descubrimiento, pero no reemplazan la validación del origen.

2.2 Según el entorno organizacional

- Internas: se originan dentro de la organización: ERP, CRM, nómina, inventarios, expedientes electrónicos, tickets y plataformas de proyectos.
- Externas: proceden de entidades públicas, proveedores, aliados, plataformas o usuarios: DANE, Banco de la República, datos.gov.co, APIs, cartografía o fuentes de mercado.
- Mixtas: combinan información propia y externa, por ejemplo, un modelo de riesgo con pagos internos e indicadores macroeconómicos.

2.3 Según su estructura

- Estructurados: tablas y esquemas definidos, como SQL, CSV y hojas de cálculo.
- Semiestructurados: JSON, XML, HTML, mensajes de eventos o correos con metadatos.
- No estructurados: PDF, texto libre, audio, imágenes, video y conversaciones; suelen requerir OCR, procesamiento de lenguaje natural o visión artificial.

2.4 Según el mecanismo de acceso

- Consulta directa a bases de datos o aplicaciones; archivos; API; flujos continuos o streaming; extracción web; y consulta manual de documentos o portales.

3. Fuentes principales en informática

Sistemas transaccionales

Registran operaciones de negocio o de la administración: ERP, CRM, facturación, inventarios, pagos, comercio electrónico, salud, educación y gestión de proyectos. Son fuentes de alto valor operativo, aunque frecuentemente se diseñan para ejecutar transacciones y no para análisis histórico. Por ello suelen alimentarse hacia almacenes de datos, lagos de datos o plataformas analíticas.

Bases de datos y repositorios

Incluyen bases relacionales, NoSQL, repositorios documentales, lagos de datos y almacenes de datos. Su elección depende del volumen, variedad, velocidad, patrón de consulta, seguridad requerida y necesidad de integración. Una arquitectura madura conserva la versión original y las versiones procesadas para permitir auditoría y reproducibilidad.

Registros de eventos y telemetría

Los logs de servidores, autenticaciones, redes, aplicaciones, microservicios y cambios de código son fuentes críticas para operación, auditoría y ciberseguridad. La National Vulnerability Database reúne datos estructurados sobre vulnerabilidades, productos afectados y métricas de impacto, ilustrando el valor de las fuentes especializadas para la gestión de riesgos tecnológicos.

Sensores, IoT y datos geoespaciales

Generan información de alta frecuencia sobre variables físicas o digitales: temperatura, calidad del aire, consumo energético, GPS, telemetría vehicular, cámaras, satélites y estaciones meteorológicas. Exigen controles sobre calibración, sincronización horaria, identificación del dispositivo, ubicación, firmware, valores

atípicos y conservación de lecturas originales.

Fuentes web, científicas y de datos abiertos

Comprenden artículos, repositorios académicos, bibliotecas digitales, portales institucionales, código fuente, catálogos y datos abiertos. Para su uso responsable se debe verificar autoría, metodología, actualización, cobertura, licencia, versión y estabilidad del acceso.

Redes sociales y plataformas digitales

Pueden apoyar monitoreo reputacional, análisis de tendencias y estudios de interacción. No obstante, no representan necesariamente a la población, pueden contener automatización, desinformación y sesgos de cobertura, y están sujetas a restricciones de privacidad y cambios de APIs. Deben triangularse con otras fuentes más robustas cuando sustenten decisiones de alto impacto.

4. Calidad, confiabilidad y trazabilidad

La disponibilidad no equivale a calidad. Una fuente es adecuada únicamente si satisface una finalidad definida. La Guía de Estándares de Calidad e Interoperabilidad de Datos Abiertos de Colombia identifica, entre otros, criterios de confidencialidad, relevancia, actualidad, trazabilidad, conformidad, exactitud, completitud, consistencia, precisión, portabilidad, credibilidad, comprensibilidad, accesibilidad, disponibilidad y unicidad.

Dimensión	Pregunta de control	Ejemplo de falla
Exactitud	¿El valor representa el hecho medido?	Precio con separador decimal incorrecto.
Completitud	¿Están todos los campos, registros o periodos?	Registros sin fecha o municipio.
Consistencia	¿Cumple reglas y no se contradice?	Fin anterior al inicio.
Actualidad	¿Es vigente para el uso previsto?	Indicador económico con corte antiguo.
Unicidad	¿Evita duplicar entidades o eventos?	Clientes repetidos con identificadores distintos.
Trazabilidad	¿Puede reconstruirse el origen y las transformaciones?	Indicador sin datos base ni fórmula documentada.
Interoperabilidad	¿Puede ser comprendido e intercambiado entre sistemas?	Códigos sin diccionario de datos.

Una matriz de evaluación puede ponderar exactitud, completitud, actualidad, trazabilidad, relevancia, interoperabilidad y seguridad. Las ponderaciones deben ajustarse al caso: en monitoreo en tiempo real prevalece la actualidad; en auditoría o investigación prevalecen la exactitud, trazabilidad y preservación de versiones.

5. Metadatos, linaje y gobierno de datos

Los metadatos describen los datos y hacen posible su búsqueda, comprensión, reutilización y control. Un registro útil debe incluir nombre, descripción, entidad productora, responsable, fechas de creación y actualización, método de captura, esquema, unidades de medida, periodicidad, granularidad, reglas de calidad, licencia, clasificación de seguridad y restricciones de uso.

El linaje de datos debe documentar toda la cadena de valor: sistema fuente → extracción → validación → limpieza → transformación → agregación → indicador o tablero. Este registro permite identificar errores, reproducir resultados, atender auditorías y explicar decisiones analíticas o automatizadas.

Componentes de gobierno recomendados

- Catálogo de datos y diccionario de variables.
- Propietarios de datos, custodios y responsables técnicos claramente asignados.
- Políticas de calidad, clasificación, retención y acceso.
- Gestión de versiones, linaje y evidencias de transformación.
- Controles de acceso basados en roles, monitoreo y registros de auditoría.
- Procedimientos para incidentes, respaldo, continuidad y recuperación.

6. Seguridad, privacidad y ética

La incorporación de una fuente debe proteger confidencialidad, integridad y disponibilidad. ISO/IEC 27001:2022 define requisitos para un sistema de gestión de seguridad de la información, dentro de un enfoque de seguridad, ciberseguridad y protección de la privacidad.

- Identificar datos personales, sensibles, reservados o confidenciales.
- Aplicar minimización: recolectar y conservar únicamente lo necesario.
- Definir finalidades de uso, controles de acceso, cifrado y registro de actividades.
- Evaluar proveedores externos, autenticidad del origen, integridad de archivos, cambios de API y continuidad del servicio.
- Aplicar anonimización o seudonimización cuando corresponda, sin asumir que la eliminación de un nombre impide por sí sola la reidentificación.
- Evitar entrenar o alimentar IA con fuentes no verificadas, sesgadas, desactualizadas o sin claridad sobre derechos de uso.

7. Arquitectura de integración recomendada

Fuentes internas y externas → captura (API, ETL/ELT, archivos, streaming) → zona de datos crudos → validación y estandarización → data lake/data warehouse → modelos analíticos, IA e indicadores → reportes, APIs y tableros.

Los controles deben ubicarse a lo largo de toda la arquitectura: validación de esquema, perfiles de calidad, detección de nulos y duplicados, normalización de códigos, gestión de identidades, cifrado, control de versiones y alertas frente a cambios de volumen, distribución o estructura.

8. Metodología de selección y uso

- Definir la decisión, pregunta, indicador, cobertura y periodicidad requeridos.
- Inventariar las fuentes candidatas y clasificarlas por origen, estructura, acceso y sensibilidad.
- Documentar metadatos mínimos, propietarios, licencias, restricciones y actualizaciones.
- Evaluar calidad, relevancia, seguridad, privacidad e interoperabilidad antes de integrarlas.
- Diseñar los procesos de extracción, transformación, carga y validación.
- Preservar fuente original, fecha de extracción, transformaciones, código, reglas y versiones.
- Monitorear cambios de calidad, actualización, disponibilidad y esquema.
- Revisar periódicamente la vigencia y retirar o recalificar fuentes que no satisfagan el propósito.

9. Consideraciones para Colombia

En estudios económicos, sociales, territoriales y de gestión pública, debe diferenciarse entre el dato original, el sistema que lo publica y el producto analítico que lo reutiliza. El portal nacional de datos abiertos y las

orientaciones de MinTIC promueven la apertura, estructuración, publicación, uso y monitoreo de datos con criterios de calidad e interoperabilidad.

Antes de incorporar una fuente colombiana a un modelo o tablero, se recomienda verificar la entidad productora, la fecha de corte, la metodología, la cobertura geográfica, las definiciones de variables, la frecuencia de actualización, el diccionario de datos, la licencia y la existencia de revisiones históricas.

Conclusiones

Las fuentes de información son activos estratégicos de la informática. Su valor no depende solamente de la cantidad de datos disponible, sino de la posibilidad de demostrar su origen, contexto, calidad, seguridad, pertinencia y condiciones de reutilización.

La práctica robusta combina gobierno de datos, metadatos, evaluación de calidad, seguridad, interoperabilidad y linaje. Esta disciplina es especialmente relevante en inteligencia artificial: la calidad, representatividad y procedencia de los datos condicionan la confiabilidad de los modelos, los indicadores y las decisiones que se toman a partir de ellos.

Referencias recientes

Las referencias se presentan en formato resumido. Se priorizan documentos, normas y guías vigentes o publicados entre 2021 y 2026.

- ISO. (2022). ISO/IEC 27001:2022 — Information security, cybersecurity and privacy protection — Information security management systems — Requirements. <https://www.iso.org/es/norma/27001>
- National Institute of Standards and Technology — NIST. (2021). SP 800-53 Rev. 5, SR-4: Provenance. <https://csf.tools/reference/nist-sp-800-53/r5/sr/sr-4/>
- NIST Computer Security Resource Center. (consulta 2026). Provenance — Glossary. <https://csrc.nist.gov/glossary/term/Provenance>
- NIST. (consulta 2026). National Vulnerability Database. <https://nvd.nist.gov/>
- Ministerio de Tecnologías de la Información y las Comunicaciones — MinTIC. (2024). Guía de Estándares de Calidad e Interoperabilidad de los Datos Abiertos del Gobierno de Colombia. <https://herramientas.datos.gov.co/herramientas/aprender-sobre-datos?page=12>
- Datos Abiertos Colombia. (2024). Iniciativa Datos Abiertos Colombia. <https://www.datos.gov.co/stories/s/Iniciativa-Datos-Abiertos-Colombia/rtfd-hr6i/>
- Datos Abiertos Colombia. (2026). Estrategia de Calidad de Datos para el Portal Nacional de Datos Abiertos. <https://www.datos.gov.co/stories/s/rkeb-yz5f>